

손실 감소와 노이즈 비교를 중심으로 분석한 그라디언트 기반 최적화 방법

최보경 이영진 이수정 김희서 문수연
수학과 소학회 MCS (Mathematics & Computer Science)
지도교수 : 김영훈 교수님

서론


과거에는 데이터의 양이 AI 모델의 성능을 좌우하는 주요 요인이었으나, 최근 10년간 데이터 양이 증가하며 가중치를 효율적으로 조정하는 최적화 기법이 성능을 결정하는 핵심 요소가 되었다. 본 포스터에서는 그라디언트 기반 최적화 기법인 GD, SGD, Mini-Batch SGD의 이론적 차이를 논의하고 더 나아가, 특정한 데이터 셋 위에서 이 세 방법을 직접 구현하여 각각의 손실 감소와 노이즈를 분석하여 비교한다.

수학적 최적화의 필요성

머신 러닝 중 단층 신경망의 지도학습을 기준으로 설명한다.

1. 지도학습 정의

: 입력 x 에 대한 모델의 예측값 $\hat{y}$ 이 정답값 y 와 유사해지도록 손실 함수¹⁾를 최소화하는 가중치²⁾를 데이터로 학습하는 것.



2. 수학적 최적화의 필요성

: 수학적 최적화는 예측값 $\hat{y}$ 과 정답값 y 가 비슷해지도록 최적의 가중치 w 를 찾기 위한 방법을 제공한다.

¹⁾ 손실 함수 : 예측값과 정답값의 차이를 나타내는 함수

²⁾ 가중치 : 학습 시, 입력값에 곱해지는 파라미터

GD

1. GD(Gradient Descent)의 정의

: 전체 데이터를 모두 사용해서 구한 empirical risk $E_n(f)$ 를 사용하여 그라디언트의 음의 방향으로 이동하며 최적값을 탐색하는 방식.

2. 과정

: 아래의 과정은 한 번의 iteration에서 일어난다.

이를 각 iteration마다 반복해 최적의 가중치를 찾는다.

1) 주어진 데이터 전부를 신경망에 입력해 예측값 $\hat{y}_n$ 를 얻음

2) 각각의 예측값과 정답값을 이용해 개별 손실 Q_n 을 계산

(Q_n 은 예측값의 개수만큼 생성)

3) 손실 Q_n 들의 평균인 $E_n(f)$ 를 구해 가중치 갱신에 사용

$$\begin{bmatrix} x_{11} & x_{12} & \cdots \\ x_{21} & x_{22} & \cdots \\ x_{31} & x_{32} & \cdots \\ \vdots & \vdots & \ddots \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ w_3 \\ \vdots \end{bmatrix} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \hat{y}_3 \\ \vdots \end{bmatrix}$$

입력 가중치 예측값

$$\text{* 가중치 업데이트 수식 : } w_{t+1} = w_t - \eta \frac{1}{N} \sum_{n=1}^N \nabla Q_n(w_t) = w_t - \eta \nabla E_n(f)(w_t)$$

w_{t+1} : 다음 업데이트에서 사용할 가중치 w_t : 현재 가중치 η : 학습률

$$Q_n = \ell(f_{w_t}(x_n), y_n) \quad E_n(f) = \frac{1}{n} \sum_{n=1}^N Q_n \quad f: \text{모델 함수}$$

SGD

1. SGD(Stochastic Gradient Descent)의 정의

: 전체 데이터 중에서 무작위로 단 하나의 데이터를 뽑아서 구한 손실 Q 를 사용하여 그라디언트의 음의 방향으로 이동하며 최적값을 탐색하는 방식.

2. 과정

: 아래의 과정은 한 번의 iteration에서 일어난다.

이를 각 iteration마다 반복해 최적의 가중치를 찾는다.

1) 주어진 데이터에서 무작위로 하나를 뽑아 신경망에

입력해 예측값 $\hat{y}$ 를 얻음

2) 예측값과 정답값을 이용해 손실 Q 계산 (하나의 Q 만 생성)

3) 손실 Q 를 가중치 갱신에 사용

$$\begin{bmatrix} x_1 & x_2 & x_3 & \cdots \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ w_3 \\ \vdots \end{bmatrix} = \begin{bmatrix} \hat{y} \end{bmatrix}$$

입력 가중치 예측값

$$\text{* 가중치 업데이트 수식 : } w_{t+1} = w_t - \eta_t \nabla Q(w_t)$$

Mini-Batch SGD

1. Mini-Batch SGD 정의

: 전체 데이터 중 일부를 무작위로 뽑아 미니배치를 구성한 뒤, 손실 $E_{B_t}(f)$ 를 사용하여 그라디언트의 음의 방향으로 이동하면서 최적값을 탐색하는 방식.

2. 과정

: 전체 데이터 중 일부를 무작위로 뽑아 미니배치를 구성한 뒤 입력값으로 사용하여 손실 $E_{B_t}(f)$ 를 구해 가중치를 갱신한다.

$$\text{* 가중치 업데이트 수식 : } w_{t+1} = w_t - \eta_t \nabla E_{B_t}(f)(w_t)$$

$$B_t: \text{미니배치} \quad E_{B_t}(f) = \frac{1}{|B_t|} \sum_{n \in B_t} Q_n$$

한계

- 1) GD : 모든 데이터를 사용하기에, 계산량이 방대해 시간/비용 면에서 비효율적이다.
- 2) SGD : 하나의 데이터만 사용하기에 노이즈가 크게 발생할 가능성이 높다.
- 3) Mini-Batch SGD : 노이즈가 작아서 지역 최적해³⁾에 갇힐 수 있다.

³⁾ 지역 최적해 : 국소적 최솟값으로, 전역 최적해가 아닌 지점.

실험을 통한 GD, SGD, Mini-Batch SGD 비교

1. 실험 주제

: 수치형 데이터 회귀 분석을 통한 최적화 기법별 손실 감소 및 학습 안정성 비교


2. 실험 설명

- Data Source: Aung Pyae. Fish Market Dataset (Kaggle)
- 데이터셋 특징 : 총 126개 샘플 (Rows) / 7개 속성 (Columns)
- 문제 정의 : 어류의 신체 치수(길이, 높이, 두께)를 독립변수로 하여 무게를 예측하는 다중 회귀 분석
- 수렴 기준 : 손실 함수가 유의미하게 감소하지 않는 구간

3. 실험 설정

- a. 모델 : 다중선형회귀 $y = wx + b$ (w : 가중치, b : 편향)
- b. 손실함수 : MSE Loss
- c. GD 배치 크기 : 126 (전체 데이터)
- d. Mini-Batch SGD 배치 크기 : 16
- e. SGD 배치 크기 : 1

[실험 1. iteration 횟수에 따른 Loss 감소 비교]



1. 실험 목적 및 전제

: 본 실험의 목적은 각 최적화 기법의 고유한 iteration 횟수에 따른 손실 감소를 비교하는 것이다. 따라서, 각 기법의 손실값의 평균이 최소화되는 학습률(lr)을 적용하였다.

2. 결과 해석


- GD에는 가장 높은 lr=0.3792690190732246를 적용하였고, 100회 미만의 iteration만에 수렴하며 iteration당 손실 감소가 가장 빨랐다.

- SGD에는 가장 낮은 lr = 0.01438449888287663을 적용하였고, 이는 약 5,000회 이상의 iteration에서 수렴하며, iteration당 손실 감소가 가장 느렸다.
- Mini-Batch SGD에는 lr=0.1438449888287663을 적용하였고, 이는 약 400회 이하의 iteration만에 수렴하며 SGD 대비 iteration당 손실 감소가 빨랐다.

3. 결론

: iteration당 손실 감소가 GD, Mini-Batch SGD, SGD 순으로 빠르게 일어남을 보였다.

[실험 2. Batch 크기에 따른 Noise 비교]



1. 실험 목적 및 전제

: 본 실험의 목적은 각 최적화 기법의 배치 사이즈에 따른 노이즈를 비교하는 것이다. 따라서, 각각의 학습률을 모두 0.0001로 동일하게 적용하였다. 그래프는 GD의 최대 iteration(50)을 기준으로 잘라 확대하여 제시하였다.

2. 결과 해석

- GD는 매 업데이트마다 노이즈가 거의 발생하지 않아 가장 부드러운 손실 곡선을 보였다.
- SGD는 매 업데이트마다 노이즈가 크게 발생해 손실 곡선이 크게 진동하며 불안정한 패턴을 보였다.
- Mini-Batch SGD는 노이즈가 줄어들어, SGD대비 진동 폭이 작고, 안정적인 곡선을 보였다.

3. 결론

: GD가 가장 매끄러운 손실 감소 곡선을 보였다.
Loss 개형 분석을 통해 노이즈 크기는 SGD > Mini-Batch SGD > GD 순으로 나타났다.

결론

본 포스터는 GD, SGD, Mini-Batch SGD의 성능을 Loss감소 속도와 노이즈 측면에서 비교하고, 각각이 갖는 학습 시간과 정확도의 상충관계를 재조명했다.

각 방법은 Loss 감소, 노이즈, 계산량 측면에서 서로 다른 장점과 단점을 지니며, 주어진 문제에 따라 적합한 선택이 달라진다.

참고 논문

L. Bottou. Large-Scale Machine Learning with Stochastic Gradient Descent. *Proceedings of COMPSTAT'2010*, pp177-186, 2010.